Augur: metodología y variaciones probadas

Insumo para el artículo · Juan David Barceló Barraza y Rafael Andrés Dede Perdomo · Ingeniería Electrónica, Universidad del Norte · 9 de noviembre de 2026

Este documento reúne, en un solo lugar, la metodología final de Augur y **todas las variaciones que se probaron** para llegar a ella: qué se cambió, cuánto cambió el resultado, si se adoptó y qué script lo reproduce en el repositorio (github.com/Ziskito/xm-spot-price-predictor). Las cifras están en COP/kWh salvo que se diga otra cosa. MAE es el error absoluto medio; DM, el estadístico de Diebold-Mariano con varianza HAC ($|t| > 1{,}96$ equivale a $p < 0{,}05$).

1. Metodología final

1.1 Información disponible al corte

Notación. D es el día que se pronostica; D-1 es el día anterior (la víspera), D-4 cuatro días antes, y D+1 y D+2 los dos días siguientes. Como el precio de bolsa se liquida por hora y la última hora de cada día es las 00:00 del día siguiente, la «ventana» del día D va de la 01:00 de D a las 00:00 de D+1.

El pronóstico se emite a las 00:00 del día D (el «corte») para la ventana de 01:00 de D a 00:00 de D+1, y solo usa lo publicado a esa hora (escenario realista): precio, demanda y generación hasta las 23:00 de D-4 (la API de XM publica con unos tres días de rezago); embalses y aportes de D-2; ONI de NOAA de dos meses antes; el predespacho ideal de D (iMAR, publicado D-1 hacia las 10:30) y el despacho programado de D (dMAR y dDEM, D-1 hacia las 14:30). Se auditó la hora de publicación de cada fuente; las ofertas de los generadores (OFEI) se descartaron porque XM agrega los precios el mes siguiente. Datos: enero de 2019 a agosto de 2026 (66.576 horas) para entrenar y validar, y la operación diaria desde el 6 de agosto.

1.2 Pronóstico de 24 horas

- **Objetivo:** log(precio / predespacho). El modelo no pronostica el precio desde cero: corrige el predespacho de XM.
- **Tres CatBoost** con pérdida MAE (1.500 árboles, profundidad 6, tasa 0,05), con conjuntos de variables distintos: R+P (realistas + predespacho, 49 variables), R+P+F+C (+ forma intradía del predespacho + despacho programado, 61) y R+P+E (+ error reciente del predespacho, 54). Se reentrenan cada mes con lo publicado hasta 73 h antes del corte y se promedian.
- **Combinador causal (QRA de la mediana)** entre el predespacho y el promedio de los CatBoost, por franjas de 6 h, reestimado cada día solo con días cuyo precio ya está publicado (margen de 5 días).
- **Bandas conformes del 80 %:** $q50 \cdot \exp(\pm m)$, con m el cuantil conforme de $|\ln(\text{real}/q50)|$ de la misma hora en los 60 días anteriores con precio publicado.
- **Detector de picos y desplomes** (HistGradientBoosting, reentrenado cada semana): probabilidad de que el precio quede ≥ 1,3 o ≤ 0,7 veces la mediana de la ventana.
- **72 h:** los pasos 1-24 son el pronóstico de 24 h. Para los pasos 25-72 (D+1 y D+2) todavía no hay predespacho, así que la referencia es el predespacho de D, con tres CatBoost por día de anticipación (los mismos tres conjuntos de variables), el mismo combinador y las mismas bandas. Las mejoras del pronóstico de 24 h se aplican también aquí, porque comparten los datos (incluido el arreglo de la demanda incompleta) y el modelo de los pasos 1-24; las del motor (ventana elegible y filtro de contrato) se validaron también con el contrato de 72 h.

1.3 Motor de decisión

- Umbrales barato y caro = percentiles 25 y 75 del pronóstico en los 30 días anteriores (método «rodante»; el usuario puede elegir de 7 a 365 días). Otros métodos: fijo (histórico 2019-2025), banda (fijo + «esperar» con banda ancha) e híbrido (rodante + banda).
- Filtro intradía: la señal favorable solo en la mitad del día que el pronóstico pone a favor del rol.
- Selección del método por estabilidad: actuar entre el 10 % y el 40 % de las horas en las dos mitades del periodo y ganar en la peor mitad (maximin).
- Filtro de precio de contrato (desde el 9-nov): comprar en bolsa solo por debajo del contrato y vender solo por encima; por defecto, el MC de XM (costo promedio de los contratos del mercado regulado).

1.4 Protocolo de validación y de adopción

Prueba fuera de muestra en 2026 (15 de enero a 5 de agosto en las comparaciones de variantes; 1 de enero a 5 de agosto en el contrato publicado), walk-forward en cinco años históricos (15 de julio a 30 de junio, 2020-21 a 2024-25) y la operación en vivo. Una variación solo se adopta si mejora con significancia (DM) y no empeora en los años históricos; si se eligió mirando 2026, se valida además en 2020-2025. Las referencias (persistencia del último precio publicado y predespacho) se evalúan en las mismas horas y con la misma información.

Tabla 1. Resultado principal: MAE con información realista, walk-forward (5 años) y 2026

Modelo	2020-21	2021-22	2022-23	2023-24	2024-25	2026
Persistencia	26,6	37,0	87,5	137,6	161,4	108,8
XGBoost	28,1	40,2	99,1	208,2	183,0	102,7
ARX+GARCH	221,5	37,0	104,6	147,9	157,8	105,0
GARCH-ged	30,4	35,9	81,3	139,3	148,6	100,6
N-BEATSx	95,2	40,6	88,9	148,1	184,2	101,7
N-HiTS	125,3	38,0	85,2	151,5	169,0	115,7
Predespacho de XM solo	13,6	12,5	23,5	37,0	59,5	39,2
Predespacho + CatBoost (Augur)	9,3	12,0	21,2	36,3	56,7	35,2

2026 = 15 de enero a 5 de agosto. Fuente: walkforward/metricas.csv (realista_walkforward_individuales.py). Con todo 2026 y la operación hasta el 31 de octubre (7.295 h, pronóstico publicado): Augur 38,6, predespacho 42,2, persistencia 116,3 (DM frente al predespacho t = 9,3).

2. Variaciones probadas

Cada tabla agrupa las variaciones de una parte del sistema. «Adoptada» significa que está en la versión publicada.

2.1 Familias de modelos

Tabla 2. Familias de modelos

Variación	Resultado	Decisión	Script
Prophet (fase inicial, con el precio de ayer)	MAE 92-96 en 2026, el peor modelo	Descartada	notebooks 04
XGBoost, ARX+GARCH, GARCH-ged (LEAR), N-BEATSx, N-HiTS desde cero	Sin el precio de ayer, ninguno supera de forma consistente a la persistencia (Tabla 1)	Descartadas como modelo principal	realista_walkforward_individuales.py
Ensamble de 6 votantes (diseño del informe de avance)	Optimista 42,9; realista apenas mejora a la persistencia (rMAE 0,93)	Reemplazado	ensamble_24h_enero.py
Ensamble de 7 con el predespacho como votante	Optimista 31,5 (41,8 con 6 votantes); realista 36,57	Reemplazado por el corrector	ensamble_con_predespacho_24h.py
Corregir el predespacho con árboles (CatBoost, LightGBM, XGBoost, Random Forest) o lineal (Lasso)	Los cuatro de árboles empatan entre sí; Lasso es peor en 3 de 6 periodos; CatBoost tiene la mejor media	CatBoost adoptado	realista_benchmark_modelos.py
N-BEATSx / N-HiTS con el predespacho como variable futura	117 → 58, lejos del CatBoost (35)	Descartada	realista_exp_neuronales.py
LEAR realista por hora	40,8-42,4	Descartada	realista_exp_lineal.py
Markov-switching (2 regímenes), modelo de dos etapas (hurdle), coeficientes recursivos (RecursiveLS)	Sin ganancia útil frente al ensamble (fase optimista, sep-2026)	Descartadas	markov_switching.py, hurdle_dos_etapas.py, recursive_ls.py

Tabla 3. Benchmark de correctores del predespacho (MAE, mismas variables y presupuesto)

Corrector del predespacho	2020-21	2021-22	2022-23	2023-24	2024-25	2026	Media
Predespacho	13,6	12,5	23,5	37,0	59,5	42,0	31,37
Pre + CatBoost	9,3	12,0	21,2	36,3	56,7	38,8	29,05
Pre + LightGBM	9,3	11,9	21,2	36,3	56,9	38,8	29,09
Pre + XGBoost	9,4	12,6	21,2	36,3	56,9	39,0	29,23
Pre + RandomForest	9,4	11,6	21,2	36,3	56,9	39,0	29,06
Pre + Lasso	9,4	12,1	21,3	36,4	56,9	39,4	29,24

Fuente: benchmark/metricas.csv (realista_benchmark_modelos.py).

2.2 Variantes del CatBoost y del entrenamiento

Tabla 4. Variantes del CatBoost (15-ene a 5-ago-2026)

Variación	MAE 2026	Decisión
Predespacho + CatBoost mensual, combinador MAE (versión simple)	35,06 (margen 5)	Base
Promedio de 3 CatBoost con variables distintas (R+P, R+P+F+C, R+P+E)	34,71 (p = 0,002); 2020-25: mejora en 3 de 5 años y empata en 2	Adoptada
3 semillas / reentreno semanal / con despacho programado por tipo de recurso	34,80 / 35,00 / 35,04 (meseta)	No (sin ganancia; el despacho por tipo choca con el alcance)
Pérdida RMSE en vez de MAE	45,8	No
CatBoost fijo hasta dic-2025 (sin reentrenar)	37,5	No: reentrenar es clave
Ponderar por antigüedad / profundidad 8 / historia desde 2023	39,9-41,2 / 39,6 / 38,2	No
Candidato afinado (desde 2021, 3.000 árboles, semanal)	34,90	No (elegido mirando 2026; meseta)

Fuente: mejoras/RESUMEN.md, mezcla_metricas.csv, variantes_cat_metricas.csv, hiper_metricas.csv, realista_validacion_historica_v2.py.

2.3 Variables de entrada

Tabla 5. Variables (CatBoost R+P, 15-ene a 5-ago-2026)

Variación	Resultado	Decisión
Forma intradía del predespacho (F)	35,08 sola; aporta dentro del promedio de 3	Adoptada en R+P+F+C
Costo marginal y demanda del despacho programado, dMAR/dDEM (C)	34,75 sola (no significativo); mejor CatBoost individual en los 5 años	Adoptada en R+P+F+C
Error reciente del predespacho (E)	34,88 (p = 0,13)	Adoptada en R+P+E
Delta ex post y precio híbrido como variables	38,9-40,4 (empeoran)	No
MPO y delta del propio predespacho	MPO ≈ costo marginal, delta ≈ 0	No
Disponibilidad declarada (OFEI) como margen de reserva	35,00 → 35,01 (p = 0,96)	No
Precios de oferta (OFEI) y pronóstico oficial de demanda	Se publican o sobrescriben después del corte (fuga)	No
Anomalía estacional de embalses (A)	36,94 → 36,42 (p = 0,24)	No
Aportes acumulados de 180 días (B)	→ 36,62 (p = 0,45)	No
ONI con 3 y 8 meses más de rezago (C)	→ 36,36 (p = 0,19)	No
Ablación por grupos (3 semillas)	Solo el precio pasado (+125,8) y el calendario (+2,9) aportan; ONI, hidrología, demanda y festivos quedan dentro del ruido	ENSO e hidrología se usan para leer la confianza, no como predictores
Demanda incompleta del último día publicado (XM publica ~26 %)	CatBoost 36,76 → 37,97 (p < 0,001); el arreglo (completar con la generación) lo devuelve a 36,76	Arreglo adoptado (5-nov)

Fuente: forma_metricas.csv, programado_metricas.csv, errorpre_metricas.csv, disponibilidad_metricas.csv, caracterizacion_metricas.csv, ablacion_logo_multisemilla.csv, demanda_parcial_metricas.csv.

2.4 Combinación y corrección del pronóstico

Tabla 6. Combinación y corrección

Variación	Resultado	Decisión
Combinador QRA con objetivo MAE, franjas de 6 h, diario	Referencia (35,02 con un CatBoost)	Adoptado

Variación	Resultado	Decisión
Objetivo sMAPE en vez de MAE	36,47 frente a 35,76 (7 votantes)	No
Hora a hora / franjas de 3 h / franjas de 12 h / un grupo	37,6 / 37,0 / 35,9 / 36,0	No
Olvido exponencial de los días viejos (vida media 30, 60, 120 días)	36,3-36,4	No
Promedio, mediana o media recortada de los votantes	62-87	No
Combinador de Kalman (pesos que se corrigen hora a hora)	Nivel 53,9, log 44,8, robusto 38,2 frente a 35,0 (DM $p < 0,001$)	No
Corrección de sesgo con errores ya publicados (global, EWMA, ventanas de 7-30 días)	Ninguna mejora; las cortas empeoran (persiguen ruido)	No
Adaptaciones a la CREG 101 127 (sep-2026): más peso a lo reciente; curva de referencia de ofertas hidráulicas	La primera empeora; la segunda mejora en 2026 pero gana en 2 de 5 años históricos y pierde en 2024-25	No

Fuente: combinador_metricas.csv, kalman_metricas.csv (realista_exp_kalman.py), bitácora del README.

2.5 Motor de decisión

Tabla 7. Motor de decisión

Variación	Resultado	Decisión
Métodos fijo, rodante, banda e híbrido	El criterio de estabilidad elige «rodante» en los cuatro casos de 2026	Rodante
Filtro intradía	Mejora la peor mitad en los cuatro casos de 2026 (por ejemplo, generador a 72 h: de 105 a 133)	Adoptado
Percentiles 10/90 a 35/65	Sin óptimo interior; 25/75 es el punto intermedio	25/75
Ventana rodante de 7, 14, 30, 60 y 90 días (5 años, 2026 y operación)	30 días estable en 7/7 y 7/7 periodos; 60 y 90 en 3-4/7	30 días (elegible en el dashboard)
Combinar ventanas cortas y largas (7+90, 14+60, 30+365)	Estables en 2-6 de 7 periodos	No
Ventana cortada en el último cambio de nivel	Casi nunca se acorta; empata o empeora	No
Umbral por tipo de día, por hora, filtro semanal	Sin ganancia frente a un umbral más exigente con la misma frecuencia	No
Histéresis y lógica difusa	Empeoran o empatan; la señal ya forma bloques	No
Filtro de precio de contrato (MC de XM)	Nunca empeora la ganancia frente al contrato; mejora en 8 de 14 casos (DM $p < 0,01$). Comercializador en la operación: −46,8 → 0,6 COP/kWh por hora	Adoptado (9-nov)
Ventana y filtro de contrato con el contrato de 72 h (2026 y operación hasta el 31-oct)	30 días estable en los dos periodos y los dos roles (60 y 90, no); el filtro nunca empeora frente al contrato (comercializador en la operación: −46,8 → 0,0 COP/kWh por hora, $p < 0,001$)	Igual que a 24 h

Fuente: motor_umbrales_alternativos.csv (realista_motor_umbrales_alternativos.py), motor_caracterizacion.csv, motor_fuzzy_histeresis.csv y la bitácora del README.

2.6 Bandas, eventos y 72 h

Tabla 8. Incertidumbre, eventos y horizonte de 72 h

Variación	Resultado	Decisión
Bandas conformes en escala log, por hora, 60 días	Cobertura 80,6 % (objetivo 80 %), ancho medio 142	Adoptadas
Bandas empíricas con residuos de 30 días (informe de avance)	Cobertura 81,0 %, ancho 137, con el ensamble anterior	Reemplazadas
Detector de eventos realista (solo lo publicado al corte)	Desplome AUC 0,94; pico 0,97: igual al optimista	Adoptado
Detector de desplome para los días 2 y 3	No supera a la climatología de forma consistente	No se publica
72 h realista (referencia: predespacho de D)	Pasos 1-24: 33,2 frente a 38,5; 25-48: 50,2 frente a 59,9; 49-72: 73,2 frente a 75,2 (cadena optimista anterior)	Adoptado

Fuente: eventos_realista.csv, eventos_72h/metricas.csv, pronostico_realista_72h.py.

3. Lecturas para el artículo

- Sin el precio de ayer (información realista), ningún modelo que pronostica desde cero supera de forma consistente a la persistencia; el predespacho de XM sí, y corregirlo con CatBoost lo mejora en todos los años evaluados.
- Lo que más importa es la pérdida L1 (MAE) y reentrenar cada mes; el resto de variantes forman una meseta.
- El ENSO y la hidrología no mejoran la precisión a 24-72 h, pero sí indican cuándo desconfiar: con El Niño y embalses bajos el error se triplica (28,5 a 97,1).
- Un mejor MAE no garantiza mejores decisiones: lo que mejoró al motor fue el filtro intradía y, frente al contrato, el filtro de precio de contrato.
- Limitaciones: el motor no es una simulación de portafolio ni de almacenamiento (BESS); la CREG 101 127 cambió las reglas en septiembre de 2026 y duplicó el error de todos los pronósticos, incluido el del predespacho.